Analyse des facteurs influençant la souscription à une offre bancaire

Sommaire

I – Introduction

Contexte du projet et objectif : comprendre quels profils de clients sont les plus susceptibles de souscrire à une offre bancaire à la suite d'une campagne de téléprospection.

II – Travail réalisé

Exploration du jeu de données, nettoyage des données, traitement des valeurs manquantes, création de variables dérivées (tranches d'âge), sélection des variables pertinentes et préparation du dataset pour l'analyse.

III – Analyse des données

Analyse descriptive des variables quantitatives et qualitatives, étude des distributions, corrélations entre variables, visualisations graphiques et comparaison des profils de clients selon la souscription.

IV – Résultats & Insights

Identification des facteurs clés influençant la souscription (durée des appels, niveau d'éducation, historique de contact, âge) et mise en évidence des profils de clients les plus réceptifs à l'offre bancaire.

V – Conclusion

Synthèse des principaux enseignements, limites de l'analyse et recommandations métier pour améliorer l'efficacité des campagnes de téléprospection.

I – Introduction

Dans un contexte de forte concurrence entre les établissements bancaires, les campagnes de téléprospection demeurent un levier important pour promouvoir des offres financières auprès des clients. Cependant, ces campagnes génèrent un volume élevé de contacts pour un taux de conversion relativement faible, ce qui représente un coût significatif pour les entreprises.

Face à cet enjeu, il devient essentiel de mieux comprendre les comportements des clients afin d'optimiser le ciblage et d'améliorer l'efficacité des actions commerciales. L'exploitation des données issues des campagnes de téléprospection permet ainsi d'identifier les facteurs qui influencent la décision de souscription à une offre bancaire.

L'objectif de ce projet est d'analyser un jeu de données contenant des informations socio-démographiques, bancaires et comportementales de clients contactés lors d'une campagne de téléprospection. À travers une analyse exploratoire des données, ce travail vise à répondre à la question suivante : **quels profils de clients sont les plus susceptibles de souscrire à une offre bancaire à la suite d'un appel téléphonique ?**

Cette étude a pour ambition de mettre en évidence les variables les plus discriminantes, de dégager des profils types de clients réceptifs et de fournir des éléments d'aide à la décision pour améliorer les futures stratégies marketing. Elle constitue également une première étape vers la mise en place d'outils analytiques ou prédictifs permettant d'optimiser les campagnes de prospection bancaire.

Données utilisées

Le jeu de données utilisé dans ce projet provient d'une **campagne de téléprospection bancaire** visant à proposer une offre financière à des clients. Il regroupe **45 211 observations**, correspondant à autant de contacts clients, et comporte **plusieurs variables descriptives** de nature quantitative et qualitative.

Les données contiennent notamment :

- des **informations socio-démographiques** (âge, profession, situation familiale, niveau d'éducation) ;
- des **informations bancaires** (solde du compte, présence de prêts ou de crédits en cours) ;
- des **informations liées à la campagne de contact** (durée du dernier appel, nombre de contacts effectués, résultat des campagnes précédentes) ;
- une **variable cible** indiquant si le client a souscrit ou non à l'offre bancaire à l'issue de la campagne.

Le dataset est majoritairement composé de clients adultes, avec une forte représentation des tranches d'âge actives, ce qui le rend cohérent avec une base de données marketing bancaire. La présence de variables variées permet une analyse complète des facteurs susceptibles d'influencer la souscription à une offre bancaire.

II – Travail réalisé

Le travail a débuté par une **exploration approfondie du jeu de données** afin de comprendre sa structure, la nature des variables et la répartition globale des observations. Cette étape a permis d'identifier les variables quantitatives et qualitatives, ainsi que de repérer d'éventuelles incohérences ou anomalies dans les données.

	id	age	job	marital	education	default	balance	housing	loan	contact	day	month	duration	campaign	pdays	previous	poutcome	y
0	id1	58	management	married	tertiary	no	2143.0	yes	no	unknown	5	may	261	1	-1	0	unknown	no
1	id2	44	technician	single	secondary	no	29.0	yes	no	unknown	5	may	151	1	-1	0	unknown	no
2	id3	33	entrepreneur	married	secondary	no	2.0	yes	yes	unknown	5	may	76	1	-1	0	unknown	no
3	id4	47	blue-collar	married	unknown	no	1506.0	yes	no	unknown	5	may	92	1	-1	0	unknown	no
4	id5	33	unknown	single	unknown	no	1.0	no	no	unknown	5	may	198	1	-1	0	unknown	no

```
df.columns
```

[6]

```
Index(['id', 'age', 'job', 'marital', 'education', 'default', 'balance',
       'housing', 'loan', 'contact', 'day', 'month', 'duration', 'campaign',
       'pdays', 'previous', 'poutcome', 'y'],
      dtype='object')
```

id : identifiant unique du client.

age : âge du client.

job : métier du client (ex : management, technician, etc.).

marital : statut marital (single, married, divorced).

education : niveau d'éducation (primary, secondary, tertiary, unknown).

default : le client a-t-il un défaut de crédit ? (yes/no).

balance : solde moyen annuel sur le compte bancaire.

housing : a-t-il un prêt immobilier ? (yes/no).

loan : a-t-il un prêt personnel ? (yes/no).

contact : type de contact utilisé pour la campagne (cellular, telephone, unknown).

day : jour du mois où le contact a eu lieu.

month : mois du contact.

duration : durée du dernier contact (en secondes).

campaign : nombre de contacts effectués durant cette campagne.

pdays : nombre de jours depuis le dernier contact (–1 signifie jamais contacté).

previous : nombre de contacts lors de campagnes précédentes.

poutcome : résultat de la précédente campagne marketing.

y : le client a-t-il souscrit à un dépôt à terme ? (target : yes/no).

```
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 45211 entries, 0 to 45210
Data columns (total 18 columns):
 #   Column     Non-Null Count  Dtype
---  ------     --------------  -----
 0   id         45211 non-null  object
 1   age        45211 non-null  int64
 2   job        45211 non-null  object
 3   marital    45211 non-null  object
 4   education  45211 non-null  object
 5   default    45211 non-null  object
 6   balance    45206 non-null  float64
 7   housing    45211 non-null  object
 8   loan       45211 non-null  object
 9   contact    45211 non-null  object
 10  day        45211 non-null  int64
 11  month      45211 non-null  object
 12  duration   45211 non-null  int64
 13  campaign   45211 non-null  int64
 14  pdays      45211 non-null  int64
 15  previous   45211 non-null  int64
 16  poutcome   45211 non-null  object
 17  y          45211 non-null  object
dtypes: float64(1), int64(6), object(11)
memory usage: 6.2+ MB
```

Un **nettoyage des données** a ensuite été effectué. Les variables non pertinentes pour l'analyse ont été supprimées afin de réduire la complexité du dataset. Les valeurs manquantes ont été identifiées et traitées de manière adaptée, notamment par suppression lorsque leur impact était négligeable ou par remplacement lorsque cela était justifié d'un point de vue analytique.

Dans une logique d'enrichissement des données, des **variables dérivées** ont été créées. En particulier, l'âge des clients a été regroupé en **tranches d'âge**, permettant une analyse plus lisible des comportements selon les grandes catégories de population (jeunes adultes, actifs,

seniors). Cette transformation facilite la comparaison entre groupes et améliore l'interprétation des résultats.

néttoyage des données

```python
# vaeurs manquantes
df.isnull().sum()
```

Python

```
id           0
age          0
job          0
marital      0
education    0
default      0
balance      5
housing      0
loan         0
contact      0
day          0
month        0
duration     0
campaign     0
pdays        0
previous     0
poutcome     0
y            0
dtype: int64
```

Recherche des valeurs manquantes : L'analyse des valeurs manquantes montre que seule la colonne balance contient des données manquantes, avec 5 valeurs nulles. Toutes les autres colonnes du jeu de données sont complètes, ce qui signifie qu'elles ne contiennent aucune valeur manquante.

Conclusion : Le dataset est globalement de bonne qualité, avec très peu de données manquantes. La colonne balance, qui représente probablement le solde du compte bancaire, nécessitera un traitement ciblé (imputation, suppression ou autre méthode) pour gérer les 5 valeurs absentes.

Étant donné que seules 5 valeurs sont manquantes dans la colonne balance sur un total de 45 211 lignes, ce nombre est négligeable. Nous choisissons donc de les ignorer afin de ne pas complexifier inutilement le traitement des données. Ce choix est justifié par le fait que ces valeurs représentent moins de 0,01 % du dataset, ce qui a un impact minimal sur l'analyse globale.

```python
mean = df["balance"].mean()
mean
```

Python

```
1362.4037074724595
```

```python
df_remplace_mean = df.fillna(mean)

df_remplace_mean.isnull().sum()
```

Python

```
id           0
age          0
job          0
marital      0
education    0
default      0
balance      0
housing      0
loan         0
contact      0
day          0
month        0
duration     0
campaign     0
pdays        0
previous     0
poutcome     0
y            0
dtype: int64
```

Lorsqu'il y a des valeurs manquantes dans une colonne numérique, il est possible de les remplacer par la moyenne de cette colonne afin de ne pas perdre d'informations. Dans ce cas, on utilise la fonction fillna(mean) pour créer un nouveau DataFrame df_remplace_mean où les valeurs manquantes ont été remplacées par la moyenne. La commande df_remplace_mean.isnull().sum() permet ensuite de vérifier qu'il n'y a plus de valeurs manquantes dans le dataset. C'est une méthode simple et efficace lorsqu'il y a très peu de données manquantes, comme ici avec seulement 5 valeurs.

Une **sélection des variables pertinentes** a ensuite été réalisée afin de se concentrer sur les facteurs susceptibles d'influencer la souscription à une offre bancaire. Les variables retenues couvrent à la fois les aspects socio-démographiques, bancaires et liés à la campagne de téléprospection.

Enfin, l'ensemble de ces étapes a permis d'aboutir à un **dataset final propre, structuré et exploitable**, prêt à être utilisé pour les analyses descriptives et l'extraction d'insights visant à identifier les profils de clients les plus enclins à souscrire à une offre bancaire.

```python
df.describe(include='all')
```

Python

	id	age	job	marital	education	default	balance	housing	loan	contact	day	month	duration	campaign	pdays	previous	poutcome
count	45211	45211.000000	45211	45211	45211	45211	45206.000000	45211	45211	45211	45211.000000	45211	45211.000000	45211.000000	45211.000000	45211.000000	45211
unique	45211	NaN	12	3	4	2	NaN	2	2	3	NaN	12	NaN	NaN	NaN	NaN	4
top	id1	NaN	blue-collar	married	secondary	no	NaN	yes	no	cellular	NaN	may	NaN	NaN	NaN	NaN	unknown
freq	1	NaN	9732	27214	23202	44396	NaN	25130	37967	29285	NaN	13766	NaN	NaN	NaN	NaN	36959
mean	NaN	40.931477	NaN	NaN	NaN	NaN	1362.403707	NaN	NaN	NaN	15.806419	NaN	258.163080	2.763841	40.197828	0.580323	NaN
std	NaN	10.623372	NaN	NaN	NaN	NaN	3044.906741	NaN	NaN	NaN	8.322476	NaN	257.527812	3.098021	100.128746	2.303441	NaN
min	NaN	10.000000	NaN	NaN	NaN	NaN	-8019.000000	NaN	NaN	NaN	1.000000	NaN	0.000000	1.000000	-1.000000	0.000000	NaN
25%	NaN	33.000000	NaN	NaN	NaN	NaN	72.000000	NaN	NaN	NaN	8.000000	NaN	103.000000	1.000000	-1.000000	0.000000	NaN
50%	NaN	39.000000	NaN	NaN	NaN	NaN	448.000000	NaN	NaN	NaN	16.000000	NaN	180.000000	2.000000	-1.000000	0.000000	NaN
75%	NaN	48.000000	NaN	NaN	NaN	NaN	1428.000000	NaN	NaN	NaN	21.000000	NaN	319.000000	3.000000	-1.000000	0.000000	NaN
max	NaN	95.000000	NaN	NaN	NaN	NaN	102127.000000	NaN	NaN	NaN	31.000000	NaN	4918.000000	63.000000	871.000000	275.000000	NaN

La commande df.describe(include='all') permet d'afficher un résumé statistique complet du DataFrame df, en incluant toutes les colonnes, qu'elles soient numériques ou catégorielles.

Ce que cela affiche : | Pour les colonnes numériques (int, float) : | - count : nombre de valeurs non nulles | - mean : moyenne | - std : écart-type | - min : valeur minimale | - 25%, 50%, 75% : quartiles | - max : valeur maximale

| Pour les colonnes catégorielles (object) : | - count : nombre de valeurs non nulles | - unique : nombre de modalités différentes | - top : modalité la plus fréquente | - freq : fréquence de cette modalité

Exemple : Pour une colonne comme job (texte), tu verras par exemple :

count : 45211

unique : 12

top : "blue-collar"

freq : 9732

Cela permet de comprendre rapidement la distribution, la diversité et la qualité des données dans chaque colonne.

III – Analyse des données

L'analyse des données repose sur une **approche descriptive et exploratoire**, visant à comprendre la répartition des variables et les relations existantes entre elles. Les variables quantitatives et qualitatives ont été étudiées séparément afin d'adapter les méthodes d'analyse et de visualisation.

```python
# premières approches
(df["age"] >= 18) & (df["education"] == "secondary")
age_sup= df[(df["age"] >= 18) & (df["education"] == "secondary")]
age_sup
```

	id	age	job	marital	education	default	balance	housing	loan	contact	day	month	duration	campaign	pdays	previous	poutcome	y
1	id2	44	technician	single	secondary	no	29.0	yes	no	unknown	5	may	151	1	-1	0	unknown	no
2	id3	33	entrepreneur	married	secondary	no	2.0	yes	yes	unknown	5	may	76	1	-1	0	unknown	no
9	id10	43	technician	single	secondary	no	NaN	yes	no	unknown	5	may	55	1	-1	0	unknown	no
10	id11	41	admin.	divorced	secondary	no	270.0	yes	no	unknown	5	may	222	1	-1	0	unknown	no
11	id12	29	admin.	single	secondary	no	390.0	yes	no	unknown	5	may	137	1	-1	0	unknown	no
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
45204	id45205	73	retired	married	secondary	no	2850.0	no	no	cellular	17	nov	300	1	40	8	failure	yes
45205	id45206	25	technician	single	secondary	no	505.0	no	yes	cellular	17	nov	386	2	-1	0	unknown	yes
45208	id45209	72	retired	married	secondary	no	5715.0	no	no	cellular	17	nov	1127	5	184	3	success	yes
45209	id45210	57	blue-collar	married	secondary	no	668.0	no	no	telephone	17	nov	508	4	-1	0	unknown	no
45210	id45211	37	entrepreneur	married	secondary	no	2971.0	no	no	cellular	17	nov	361	2	188	11	other	no

23199 rows × 18 columns

Les **variables quantitatives** (âge, solde du compte, durée du dernier appel, nombre de contacts, etc.) ont fait l'objet d'analyses de distribution à l'aide d'histogrammes, de courbes de densité et de boîtes à moustaches. Ces visualisations ont permis d'identifier des distributions asymétriques, la présence de valeurs extrêmes et les tendances centrales des données.

Visualisation des variables quantitatives univariées

```
# histogramme de la variable age
plt.hist(df_majeur["age"], bins=20, edgecolor="black", color="yellow")
plt.Figure(figsize=(10, 6))
plt.title("Histogramme de l'âge des clients majeurs")
plt.xlabel("Âge")
plt.ylabel("Fréquence")
plt.show()
```

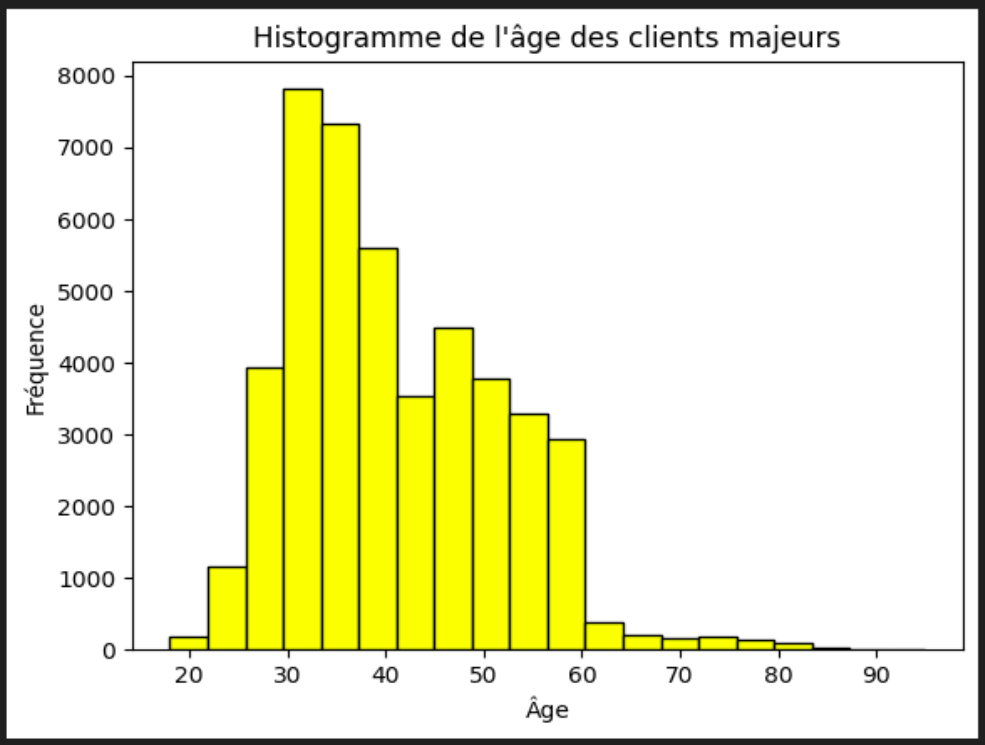

```python
plt.boxplot(df_majeur["age"])
plt.title("Boîte à moustaches de l'âge des clients majeurs")
plt.xlabel("Âge")
plt.ylabel("Valeurs")
plt.show()
```

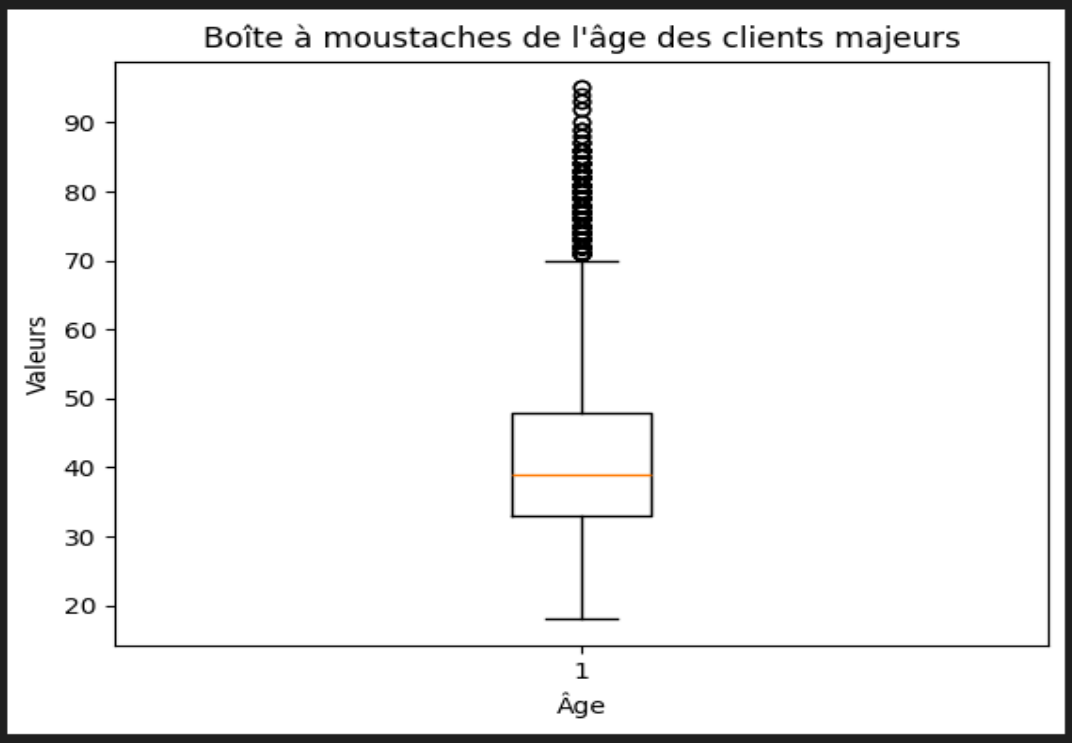

nterprétation du graphique : La boîte centrale représente les 50 % des valeurs centrales :

```python
# Histogramme durée de la dernière communication en seconde

sns.histplot(df["duration"])
plt.title("Histogramme de la durée de la dernière communication en secondes")
plt.xlabel("Durée (secondes)")
plt.ylabel("Fréquence")
plt.show()
```

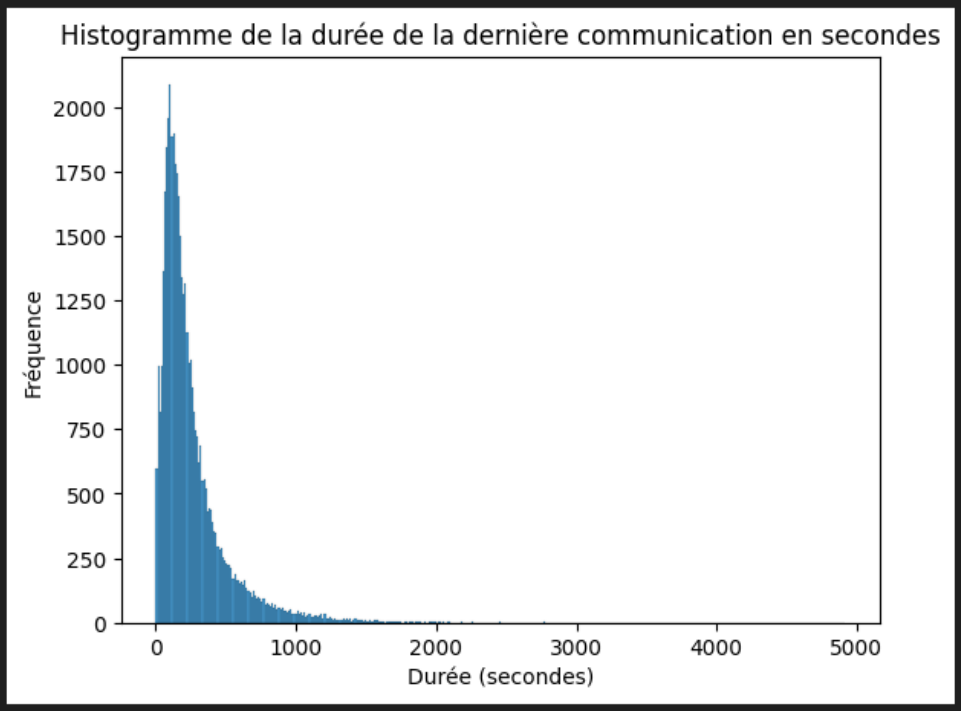


```python
sns.boxplot(df_majeur["duration"])
plt.title("Boîte à moustaches de la durée de la dernière communication en secondes")
plt.xlabel("Durée (secondes)")
plt.ylabel("Valeurs")
plt.show()
```

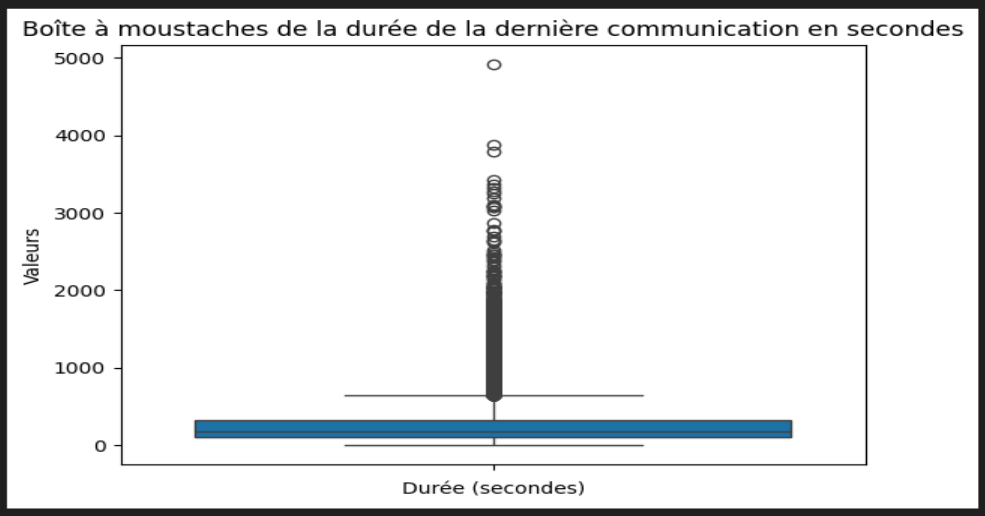

```python
sns.kdeplot(df["duration"], fill=True)
plt.title("Densité de la durée de la dernière communication en secondes")
plt.xlabel("Durée (secondes)")
plt.ylabel("Densité")
plt.show()
```

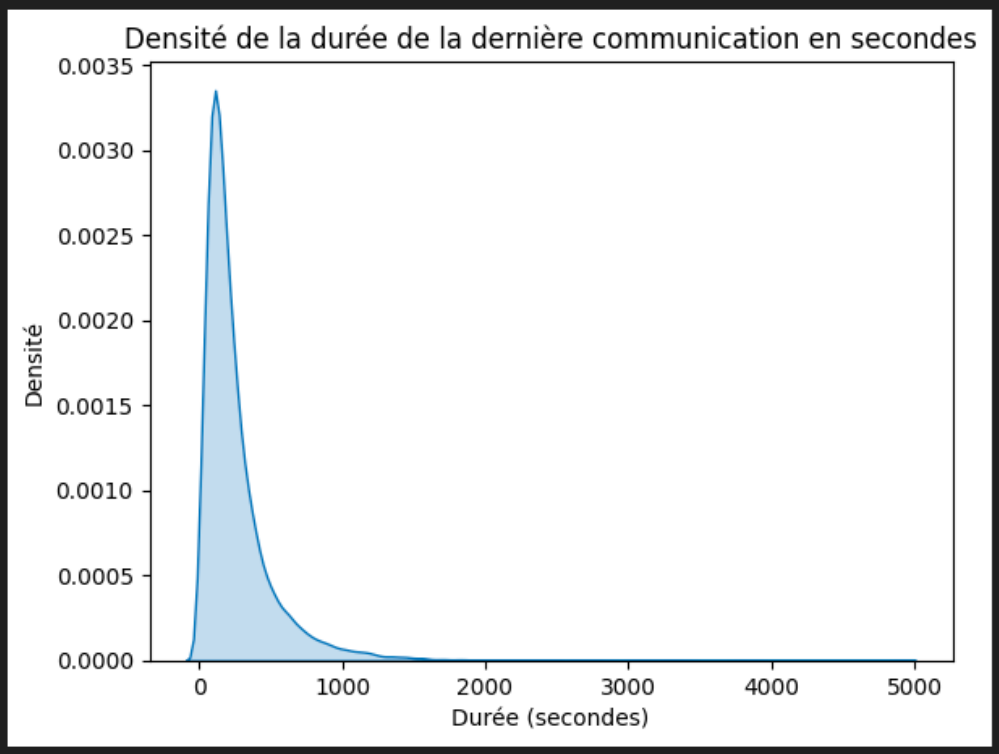

Les **variables qualitatives** (niveau d'éducation, profession, situation familiale, type de contact, résultat des campagnes précédentes) ont été analysées à l'aide de tableaux de fréquences et de graphiques en barres. Cette étape a permis d'identifier les modalités les plus représentées et de mieux comprendre la structure de la population étudiée.

Visualisation des variables qualitatives univariées

```
effectif = df_majeur["education"].value_counts().reset_index()
effectif
```

	education	count
0	secondary	23199
1	tertiary	13298
2	primary	6849
3	unknown	1857

La majorité des individus ont un niveau d'études secondaires (secondary), soit plus de la moitié de l'échantillon.

Un tiers environ ont un niveau supérieur (tertiary), ce qui indique une population plutôt qualifiée.

Les personnes avec un niveau primaire sont nettement moins nombreuses.

Le nombre de cas où l'éducation est non renseignée (unknown) reste faible (environ 4 % du total), ce qui est un bon indicateur de qualité des données.

Empty markdown cell, double-click or press enter to edit.

```
color= ["red", "blue", "green", "orange", "purple"]
plt.bar(effectif["education"],  effectif["count"], color=color )
# ajouter les values sur les barres
for i, v in enumerate(effectif["count"]):
    plt.text(i, v + 0.5, str(v), ha='center', va='bottom')
plt.title("Effectif par niveau d'éducation")
plt.xlabel("Niveau d'éducation")
plt.ylabel("Effectif")
plt.show()
```

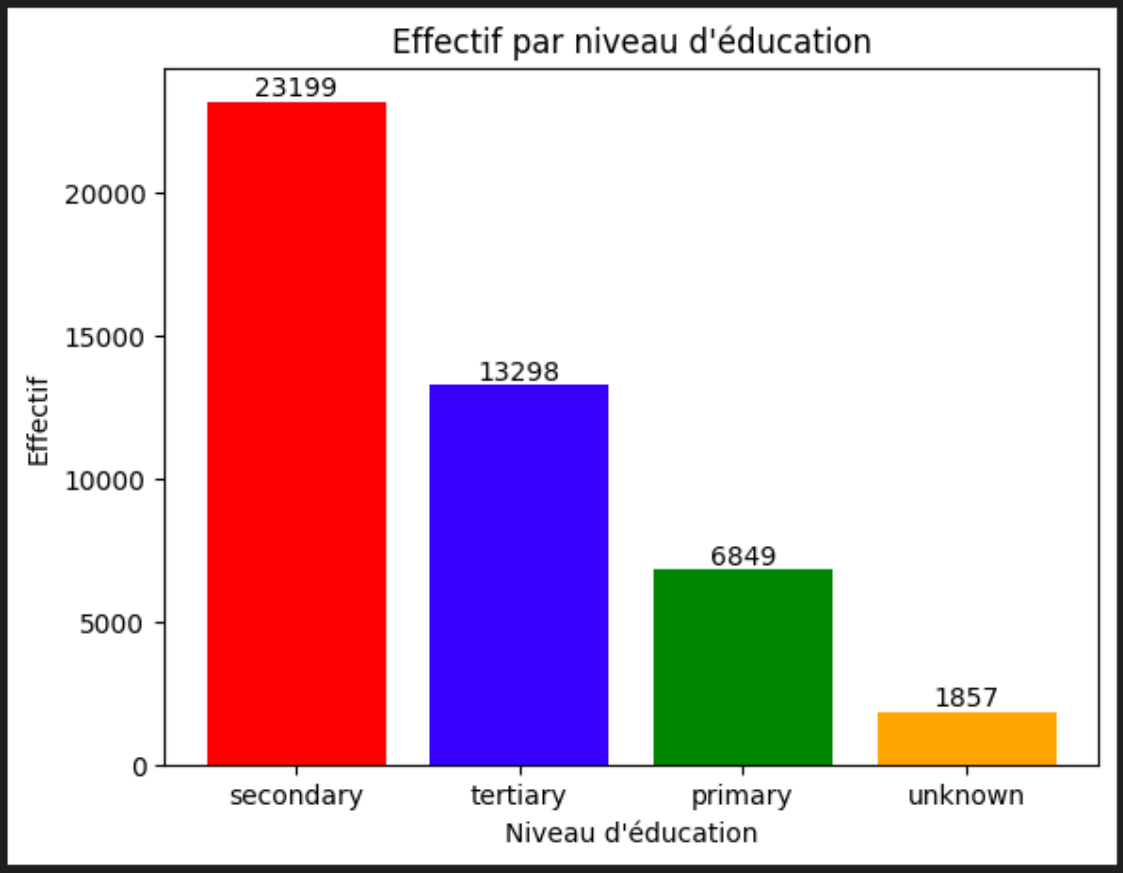

```python
# Correction du calcul de la proportion (erreur de syntaxe : 100=... → à remplacer par 100 * ...)
effectif["proportion"] = round(100 * effectif["count"] / effectif["count"].sum(), 2)

# Création du graphique en barres
plt.bar(effectif["education"], effectif["proportion"], color=color)

# Ajout des valeurs sur les barres
for i, v in enumerate(effectif["proportion"]):
    plt.text(i, v + 0.5, str(v), ha='center', va='bottom')

# Titres et étiquettes
plt.title("Effectif par niveau d'éducation")
plt.xlabel("Niveau d'éducation")
plt.ylabel("Proportion (%)")
plt.show()
```

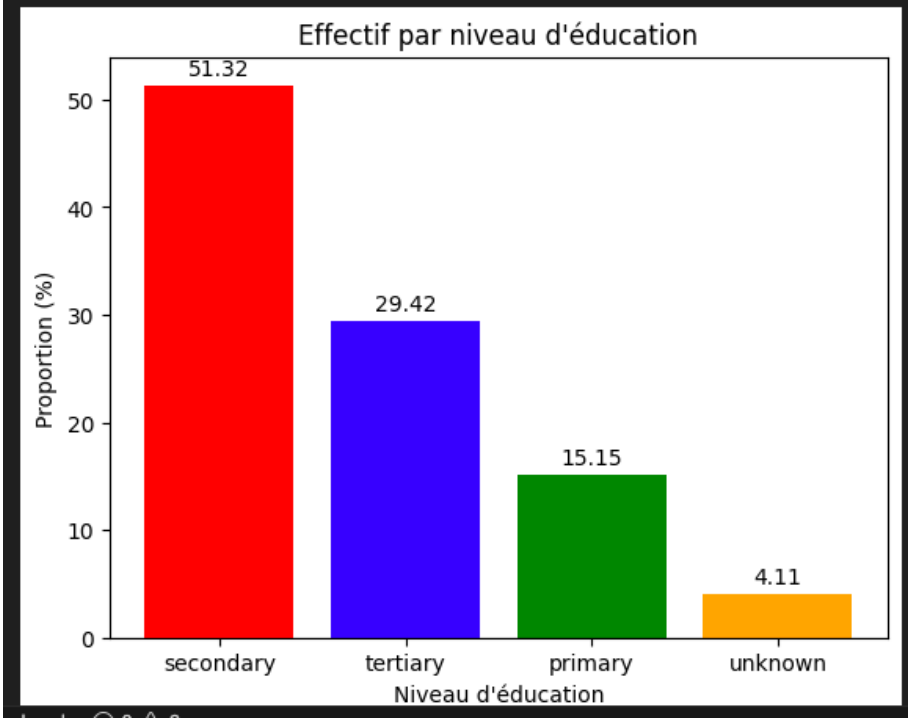

Une **analyse des relations entre variables** a ensuite été réalisée, notamment en comparant les profils des clients ayant souscrit à l'offre bancaire avec ceux n'ayant pas souscrit. Des comparaisons croisées ont permis de mettre en évidence des différences significatives selon certains critères, tels que l'âge, le niveau d'éducation ou la durée du dernier appel téléphonique.

~/Desktop/projet_banque/analyse banque.ipynb | Visualisation des variables qualitatives univariées > M↓ Analyse :

Generate + Code + Markdown | Run All | Clear All Outputs | Outline ···

Analyses bivariées

[35]
```
sns.boxplot(x="y", y="duration", palette=color, data=df_majeur)
```

```
/var/folders/dl/grllz11s10j3k3rm1rt8w0nw0000gn/T/ipykernel_7704/1412045988.py:1: FutureWarning:

Passing `palette` without assigning `hue` is deprecated and will be removed in v0.14.0. Assign the

  sns.boxplot(x="y", y="duration", palette=color, data=df_majeur)
/var/folders/dl/grllz11s10j3k3rm1rt8w0nw0000gn/T/ipykernel_7704/1412045988.py:1: UserWarning: The pa
  sns.boxplot(x="y", y="duration", palette=color, data=df_majeur)
```

```
<Axes: xlabel='y', ylabel='duration'>
```

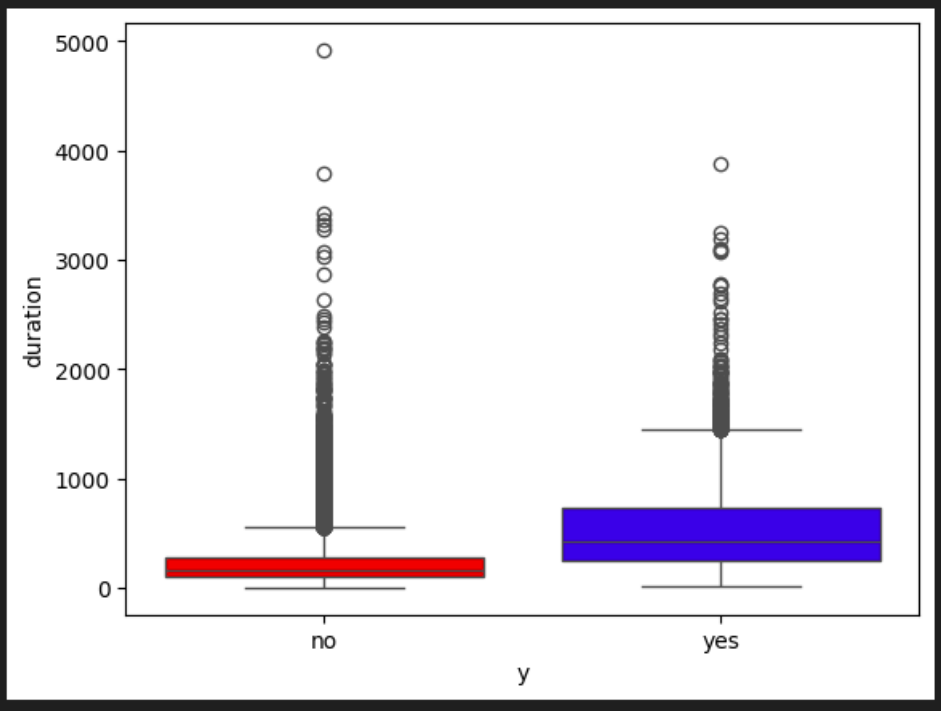

```python
sns.boxplot(x="y", y="age", palette=color, data=df_majeur)
```

```
/var/folders/dl/grllz11s10j3k3rm1rt8w0nw0000gn/T/ipykernel_7704/771432754.py:1: FutureW

Passing `palette` without assigning `hue` is deprecated and will be removed in v0.14.0

  sns.boxplot(x="y", y="age", palette=color, data=df_majeur)
/var/folders/dl/grllz11s10j3k3rm1rt8w0nw0000gn/T/ipykernel_7704/771432754.py:1: UserWa
  sns.boxplot(x="y", y="age", palette=color, data=df_majeur)

<Axes: xlabel='y', ylabel='age'>
```

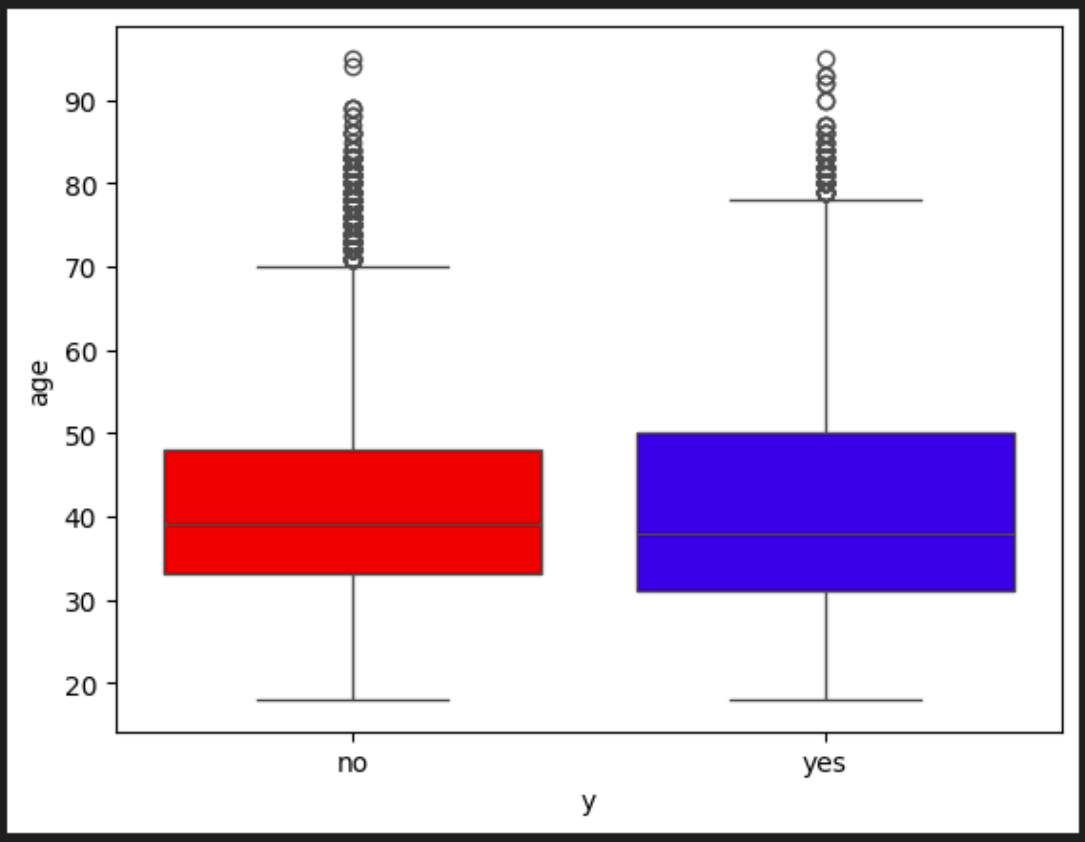


```python
table_contingence = pd.crosstab(df_majeur["y"], df_majeur["education"])
table_contingence
```

Python

education	primary	secondary	tertiary	unknown
y				
no	6258	20749	11302	1605
yes	591	2450	1996	252

Analyse : Tous les niveaux d'éducation enregistrent des souscriptions (yes), mais avec des proportions très différentes.

Le taux de conversion (souscriptions par rapport au total) semble :

Plus élevé pour les niveaux tertiaire et unknown

Moins élevé pour les niveaux primary et secondary, en dépit de leurs effectifs plus élevés

Conclusion : Même si le nombre brut de souscriptions est plus élevé chez les personnes ayant un niveau secondaire (2 450), cela s'explique surtout par leur grand effectif total. Pour mesurer l'impact réel du niveau d'éducation sur la souscription, il serait pertinent de calculer les taux de souscription par niveau (ex. : yes / (yes + no)), afin d'identifier les profils les plus réceptifs.

```
sns.countplot(x="y", hue="education", data=df_majeur, palette=color)
```

```
/var/folders/dl/grllz11s10j3k3rm1rt8w0nw0000gn/T/ipykernel_7704/1496112247.py:1: UserWarning:
  sns.countplot(x="y", hue="education", data=df_majeur, palette=color)

<Axes: xlabel='y', ylabel='count'>
```

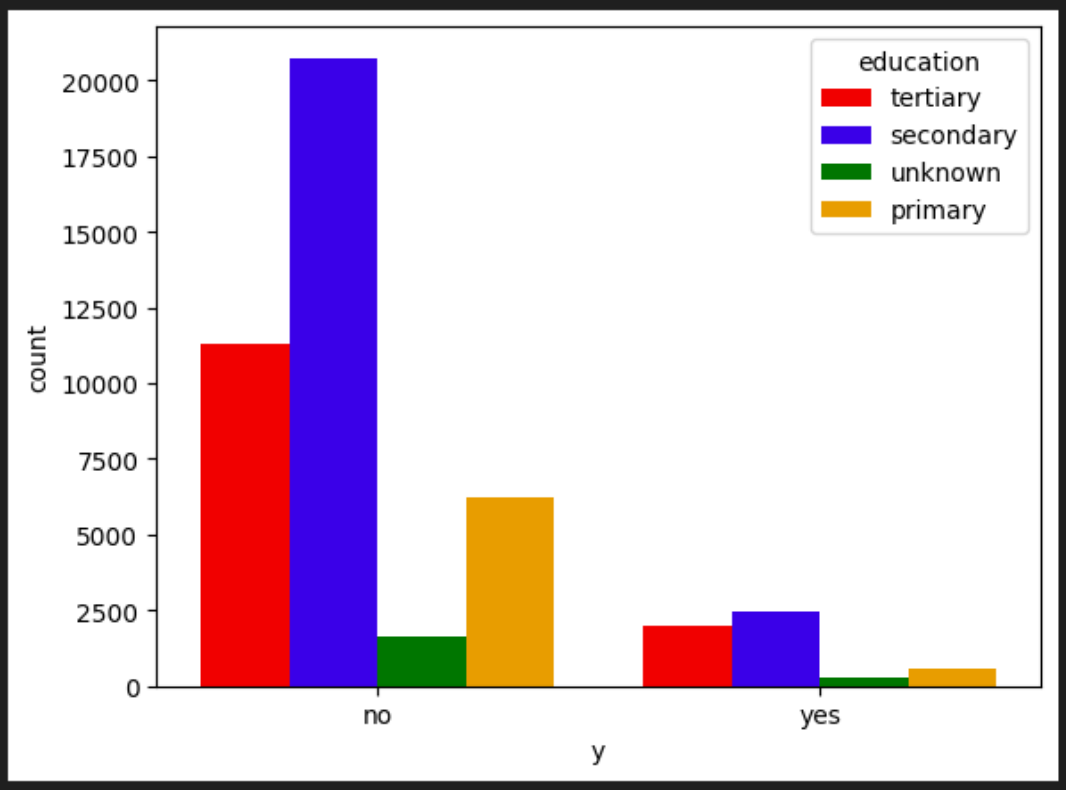


```
prop_tabale = df_majeur.groupby("y")["education"].value_counts(normalize=True).reset_index(name='proportion')
prop_tabale
```

Pyth

	y	education	proportion
0	no	secondary	0.519843
1	no	tertiary	0.283159
2	no	primary	0.156787
3	no	unknown	0.040211
4	yes	secondary	0.463226
5	yes	tertiary	0.377387
6	yes	primary	0.111741
7	yes	unknown	0.047646

Interprétation : Parmi les clients ayant souscrit (yes) :

Les niveaux secondary (46,3 %) et surtout tertiary (37,7 %) sont dominants.

Le niveau tertiary est proportionnellement plus représenté que chez les non-souscripteurs, ce qui suggère une meilleure réceptivité à l'offre.

Le niveau primary (11,2 %) est peu présent, indiquant une faible propension à souscrire.

Parmi les non-souscripteurs (no) :

La majorité vient du groupe secondary (52 %), mais cela reflète surtout sa forte représentation globale dans la base.

Conclusion : Les clients avec un niveau tertiaire sont proportionnellement plus enclins à souscrire que les autres. Ce tableau confirme que le niveau d'éducation est un facteur pertinent à prendre en compte dans une stratégie de ciblage marketing ou un modèle prédictif.

```
sns.barplot(x="y", y="proportion", hue="education", data=prop_tabale, palette=color)
```

```
/var/folders/dl/grllz11s10j3k3rm1rt8w0nw0000gn/T/ipykernel_7704/206569462.py:1: UserWarning: The
  sns.barplot(x="y", y="proportion", hue="education", data=prop_tabale, palette=color)

<Axes: xlabel='y', ylabel='proportion'>
```

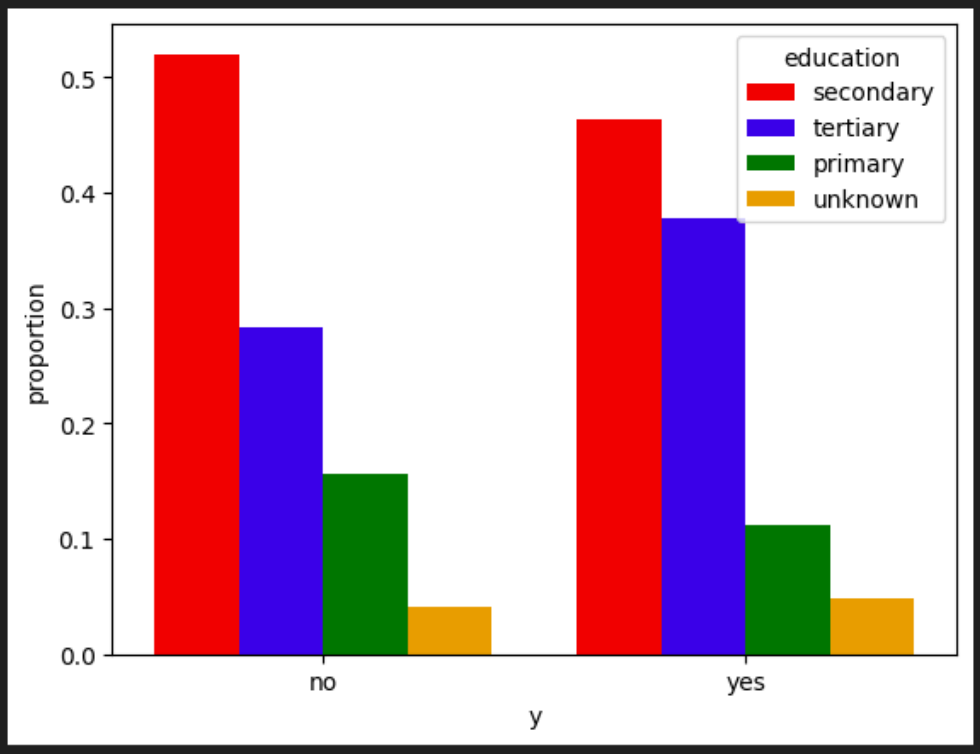

```
Click to add a breakpoint ration", y="age", data=df_majeur)
plt.title("Nuage de points entre la durée et l'âge")
plt.xlabel("Durée (secondes)")
plt.ylabel("Âge")
plt.show()
```

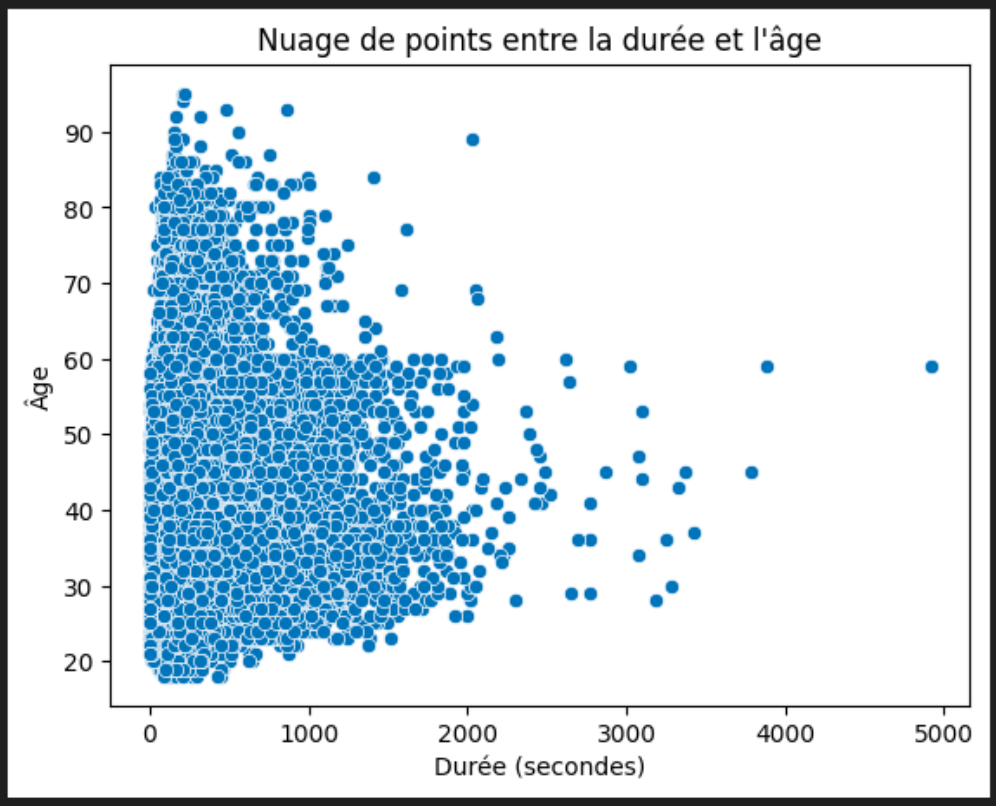

```python
df_quanti = df_majeur.select_dtypes(include=['int64', 'float64'])
df_quanti
```

	age	balance	day	duration	campaign	pdays	previous
0	58	2143.0	5	261	1	-1	0
1	44	29.0	5	151	1	-1	0
2	33	2.0	5	76	1	-1	0
3	47	1506.0	5	92	1	-1	0
4	33	1.0	5	198	1	-1	0
...	...	...	...	...	...	...	...
45206	51	825.0	17	977	3	-1	0
45207	71	1729.0	17	456	2	-1	0
45208	72	5715.0	17	1127	5	184	3
45209	57	668.0	17	508	4	-1	0
45210	37	2971.0	17	361	2	188	11

45203 rows × 7 columns

```python
mat_corr = df_quanti.corr()
mat_corr
```

	age	balance	day	duration	campaign	pdays	previous
age	1.000000	0.097827	-0.009113	-0.004639	0.004765	-0.023758	0.001290
balance	0.097827	1.000000	0.004350	0.021557	-0.014647	0.003387	0.016644
day	-0.009113	0.004350	1.000000	-0.030240	0.162388	-0.093154	-0.051776
duration	-0.004639	0.021557	-0.030240	1.000000	-0.084585	-0.001574	0.001197
campaign	0.004765	-0.014647	0.162388	-0.084585	1.000000	-0.088673	-0.032882
pdays	-0.023758	0.003387	-0.093154	-0.001574	-0.088673	1.000000	0.454811
previous	0.001290	0.016644	-0.051776	0.001197	-0.032882	0.454811	1.000000

```
sns.heatmap(mat_corr, annot=True, cmap='coolwarm', fmt='.2f')
```

```
<Axes: >
```

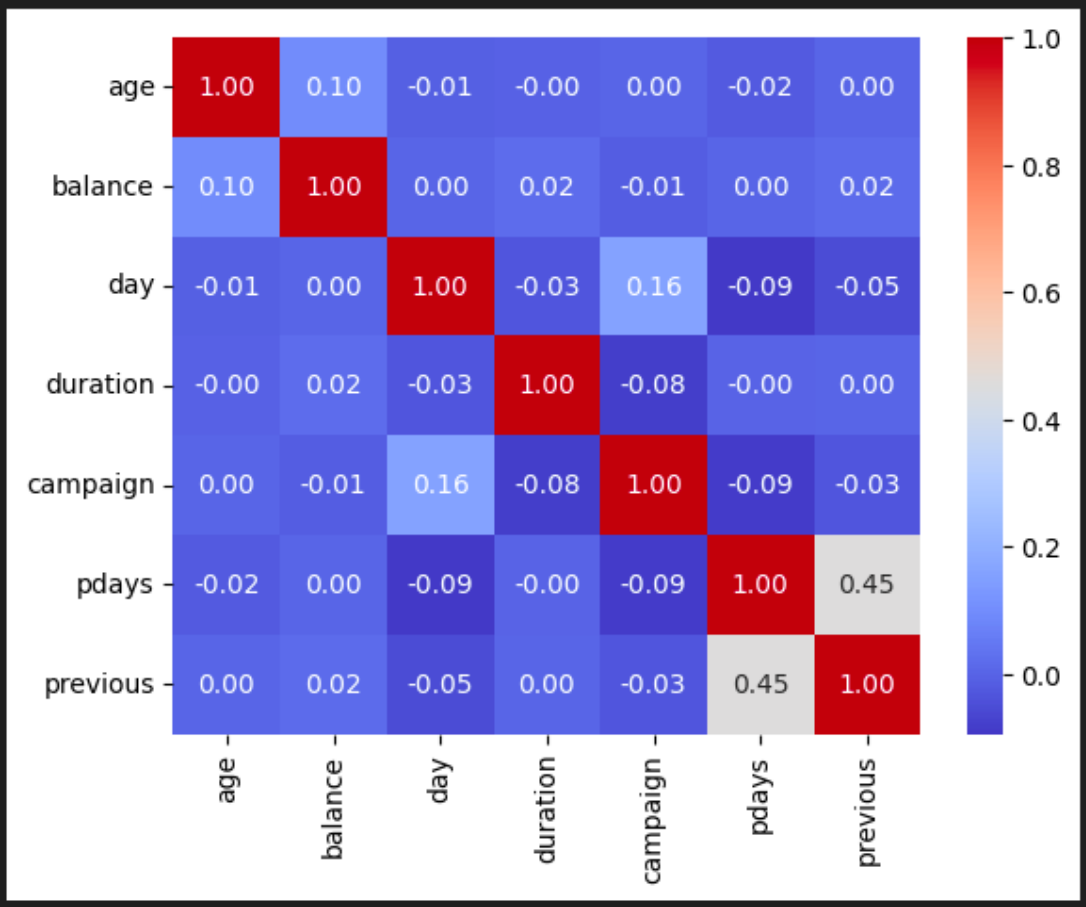

Enfin, l'ensemble des **visualisations graphiques** produites a facilité l'interprétation des résultats et la mise en évidence de tendances clés. Cette analyse exploratoire constitue une base solide pour identifier les facteurs les plus influents dans la décision de souscription et orienter les conclusions du projet.

IV – Résultats & Insights

L'analyse des données a permis d'identifier plusieurs **facteurs clés influençant la souscription à une offre bancaire** à l'issue d'une campagne de téléprospection. Ces résultats mettent en évidence des tendances nettes dans le comportement des clients et permettent de dégager des profils particulièrement réceptifs.

La **durée du dernier appel téléphonique** apparaît comme l'un des facteurs les plus déterminants. Les clients ayant souscrit à l'offre présentent, en moyenne, des appels significativement plus longs que ceux n'ayant pas souscrit. Cela suggère qu'un échange plus approfondi avec le conseiller augmente fortement la probabilité de conversion.

Le **niveau d'éducation** joue également un rôle dans la décision de souscription. Certaines catégories, notamment les clients ayant un niveau d'éducation secondaire ou non renseigné, montrent une propension légèrement plus élevée à souscrire que les autres groupes. Cette observation souligne l'importance d'adapter le discours commercial en fonction du profil éducatif du client.

L'**historique de contact** constitue un autre facteur discriminant. Les clients ayant déjà été contactés lors de campagnes précédentes, en particulier lorsque ces campagnes avaient abouti à un résultat positif, sont plus enclins à souscrire à une nouvelle offre. À l'inverse, les contacts répétés sans succès semblent avoir un impact limité sur la conversion.

Enfin, l'**âge** permet de distinguer des comportements différents selon les tranches de population. Les adultes en âge actif, notamment ceux âgés de 25 à 50 ans, représentent la majorité des souscriptions, tandis que les clients plus jeunes ou très âgés sont nettement moins réceptifs à ce type de démarche commerciale.

Dans l'ensemble, ces résultats permettent de **dresser des profils types de clients les plus susceptibles de souscrire** : des clients adultes, ayant déjà interagi avec la banque, et pour lesquels l'échange téléphonique a été suffisamment long et engageant. Ces insights constituent un levier stratégique pour améliorer le ciblage et l'efficacité des futures campagnes de téléprospection.

V – Conclusion

Ce projet d'analyse a permis de mettre en lumière les **principaux facteurs influençant la souscription à une offre bancaire** à la suite d'une campagne de téléprospection. L'étude a montré que la durée de l'appel, l'historique de contact, le niveau d'éducation et l'âge des clients jouent un rôle déterminant dans la probabilité de conversion.

Les résultats soulignent notamment l'importance de la **qualité de l'échange téléphonique** : des appels plus longs et plus engageants sont associés à un taux de souscription plus élevé. De même, les clients ayant déjà été exposés à des campagnes précédentes, en particulier avec un historique positif, apparaissent comme des cibles privilégiées. Les analyses mettent également en évidence une réceptivité plus marquée chez les clients adultes en âge actif, confirmant la pertinence de ce segment pour les campagnes marketing bancaires.

Toutefois, cette analyse présente certaines **limites**. Elle repose sur des données historiques et ne permet pas d'établir de relations causales directes. De plus, certaines variables, comme la qualité du discours commercial ou le profil précis du conseiller, ne sont pas disponibles dans le dataset et pourraient influencer les résultats. La présence de valeurs extrêmes et de déséquilibres entre les classes de souscription constitue également un point de vigilance.

Sur le plan métier, plusieurs **recommandations** peuvent être formulées. Il est conseillé de prioriser les clients présentant un historique de contact favorable, d'adapter le discours commercial en fonction du profil socio-démographique et d'encourager des échanges téléphoniques plus qualitatifs. Enfin, ces résultats ouvrent la voie à des travaux futurs, notamment la mise en place de **modèles prédictifs** visant à estimer la probabilité de souscription et à optimiser le ciblage des campagnes de téléprospection bancaire.